



University
of Basel

Gaussian Process Morphable Models


KI, der wir vertrauen können

Marcel Lüthi, Departement Mathematik und Informatik, Universität Basel

Übersicht

1. Künstliche Intelligenz und variational Autoencoders
2. Gaussian Process Morphable Models
3. Modellierung mit Gaussian Process Morphable Models

Anwendungsbeispiel: Design eines Nasenimplantats



Mein Background


Dozent Informatik

Forschung im Bereich Formmodellierung und Bildanalyse

- Probabilistische Modellierung
- Bayessche Methoden / Analysis by Synthesis
- Anwendung in der Medizin

Autor/Maintainer der Opensource Software Scalismo

Mitgründer Shapemeans GmbH




Was ist Künstliche Intelligenz?




Intelligence measures an agent's ability to achieve goals **in a wide range of environments**.

Shane Legg and Marcus Hutter. A collection of definitions of intelligence. 2007.


KI in der Praxis – maschinelles lernen



Quelle:Wikipedia.org




Quelle:Wikipedia.org




Quelle:Wikipedia.org

Manifold-Hypothese

Hochdimensionale Daten der realen Welt liegen auf einer tief-dimensionalen Oberfläche die im hochdimensionalen Raum, beobachteten Raum, eingebettet ist.




Beispielsystem: Variational Autoencoder




Kingma, Durk P., et al. "Semi-supervised learning with deep generative models."
"Advances in neural information processing systems 27 (2014).

Autoencoder als generative Modelle



Anwendungen von generativen Modellen




Datengenerierung

- Testen auf realistischen, aber simulierten Daten



Design von Implantaten

- Finde wahrscheinlichste Form zu gegebener Form

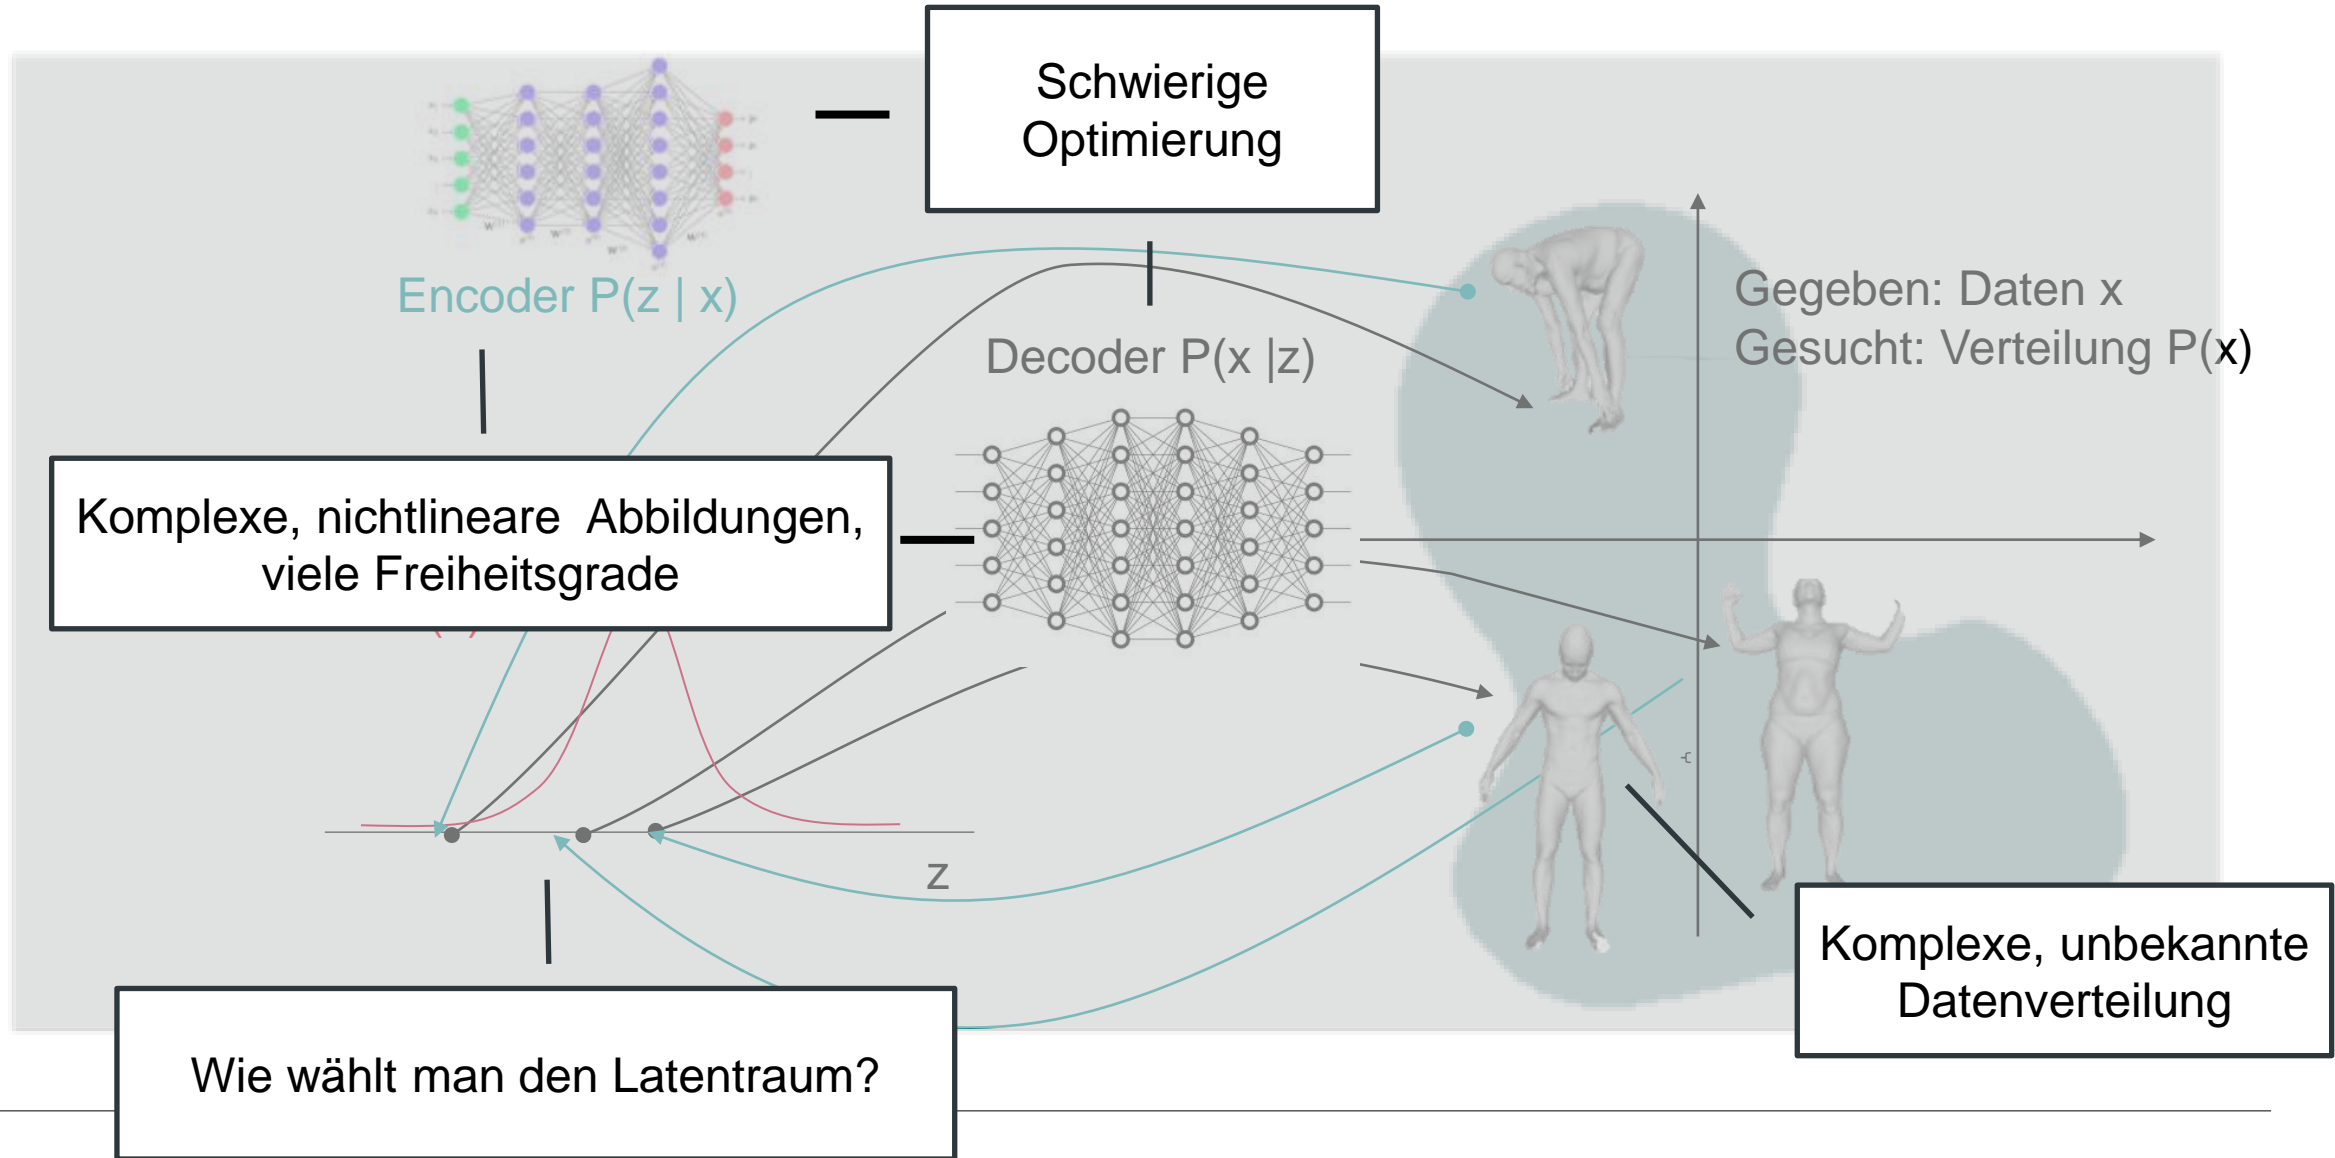


Shape und Bildanalyse

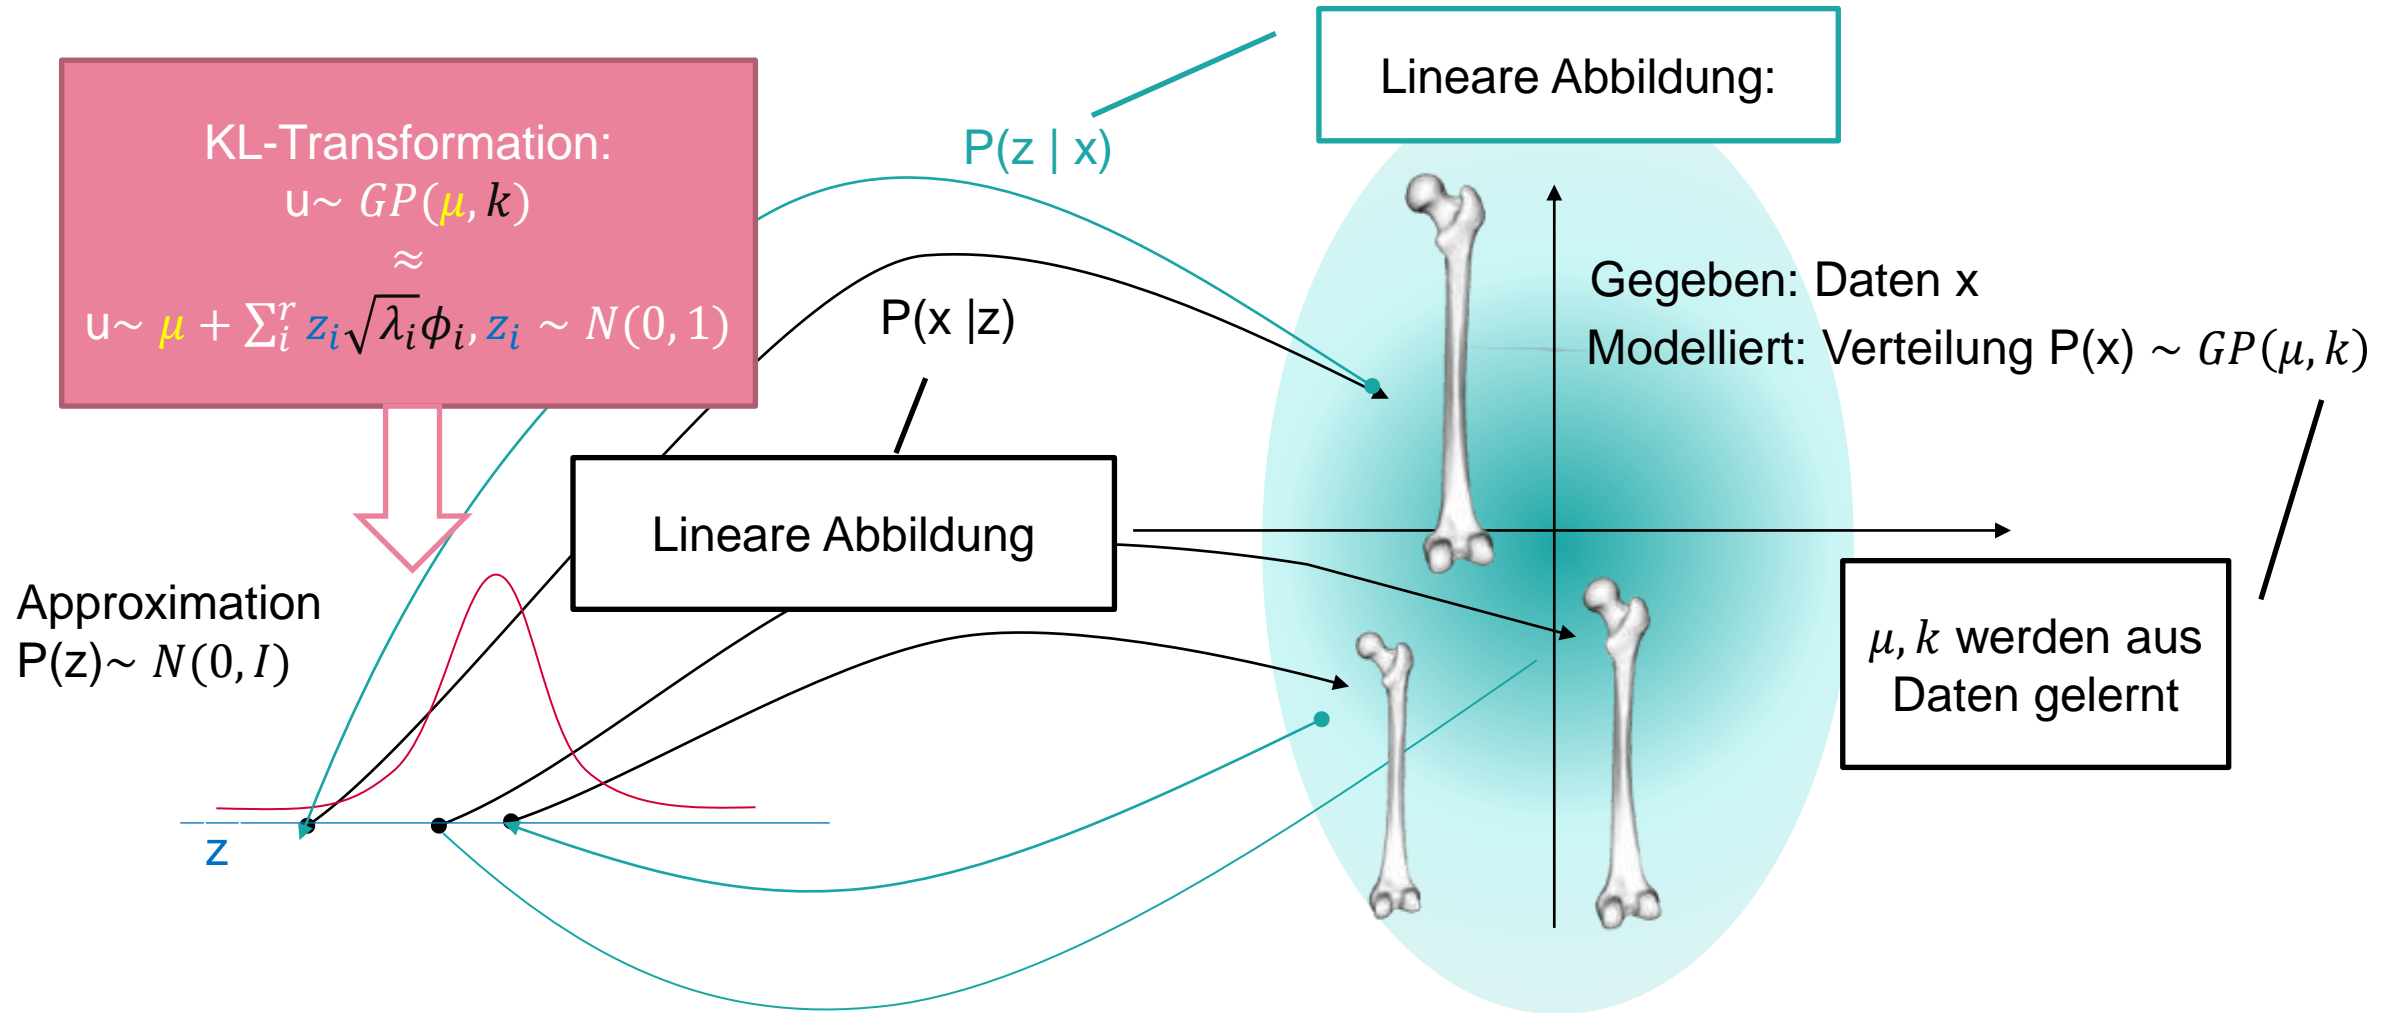
- Diagnose
- Operationsplanung
- Statistische Inferenz auf Formen

Gaussian process morphable models

Variational Autoencoder



Gaussian Process Morphable Models




Lüthi, Marcel, et al. "Gaussian process morphable models."



IEEE transactions on pattern analysis and machine intelligence 40.8 (2017): 1860-1873.

Wann macht Annahme Sinn?

- Formveränderungen sind nicht zu gross
- Ein klarer Mittelwert existiert
- Punkt-zu-Punkt Korrespondenz existiert
- Rotation/Translation ist normalisiert




Gut fundierte Statistische Theorie

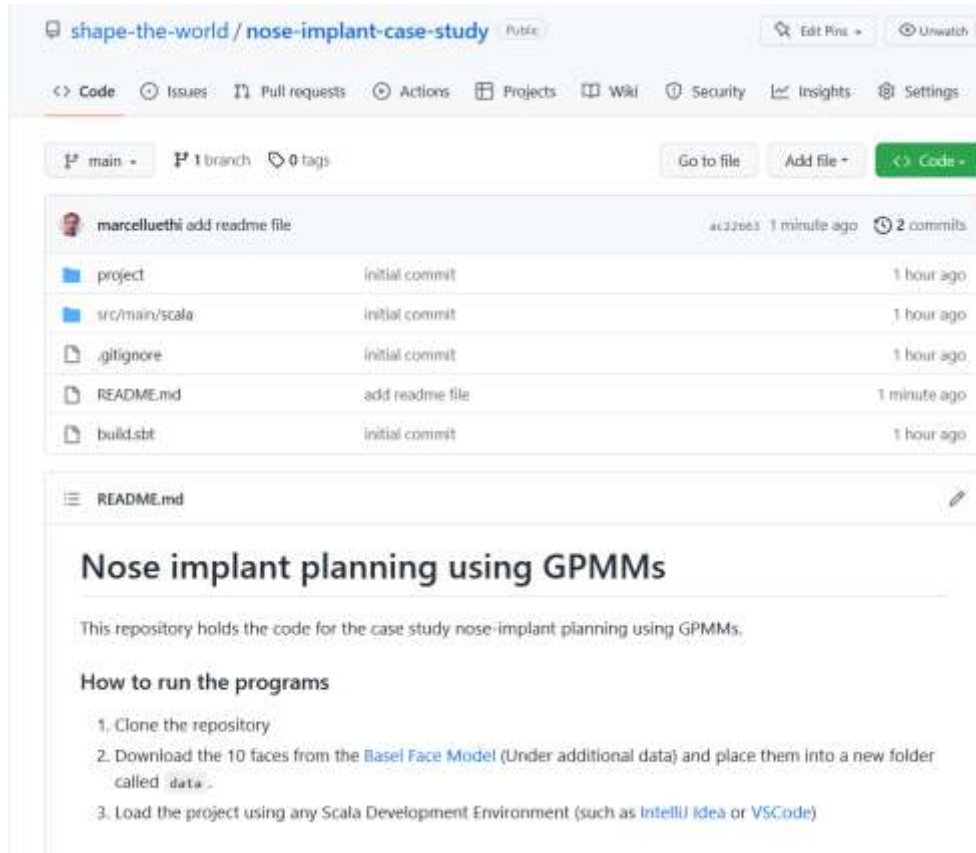


On Growth and Form, D. Thompson, 1917

Modellieren mit GPMMs




Code, Daten und Dokumentation online verfügbar



<https://github.com/shape-the-world/nose-implant-case-study>

Problemstellung

Gegeben





Gesucht



Datensatz: Öffentliche Gesichter des Basel Face Model (faces.dmi.unibas.ch)

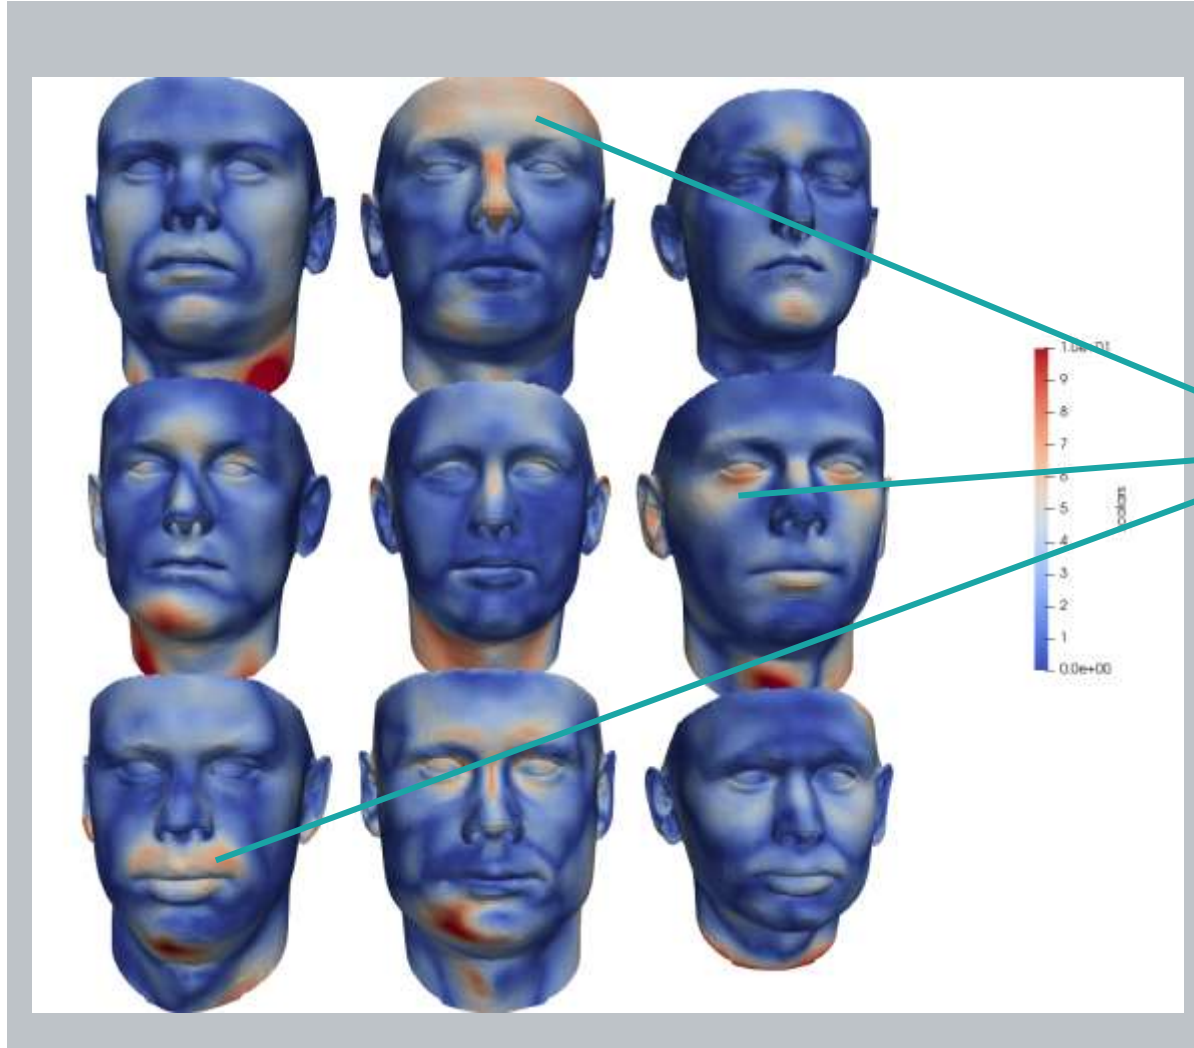
Aus zwei Gesichtern werden viele Gesichter



Modell aus 9 Gesichtern



Beste Rekonstruktion – Leave one out Experiment




Beobachtung:
Fehler sind lokal und
glatt auslaufend

Modellieren mit Gaussian Prozessen

Gauss Prozesse unterstützen flexible Algebra zum Modellieren.

$$u \sim GP(\mu_{PDM}, k_{PDM} + k_{Gauss})$$

$$k_{Gauss}(x, x') = \exp\left(-\frac{\|x - x'\|^2}{\sigma}\right)$$




Modelliert fehlende Variabilität

Modell aus 9 Gesichtern mit zusätzlicher Flexibilität




Beste Rekonstruktion – Leave one out Experiment

Nur Daten





Mit zusätzlicher Flexibilität



Vorhersagen der Nase

Mathematisches Problem

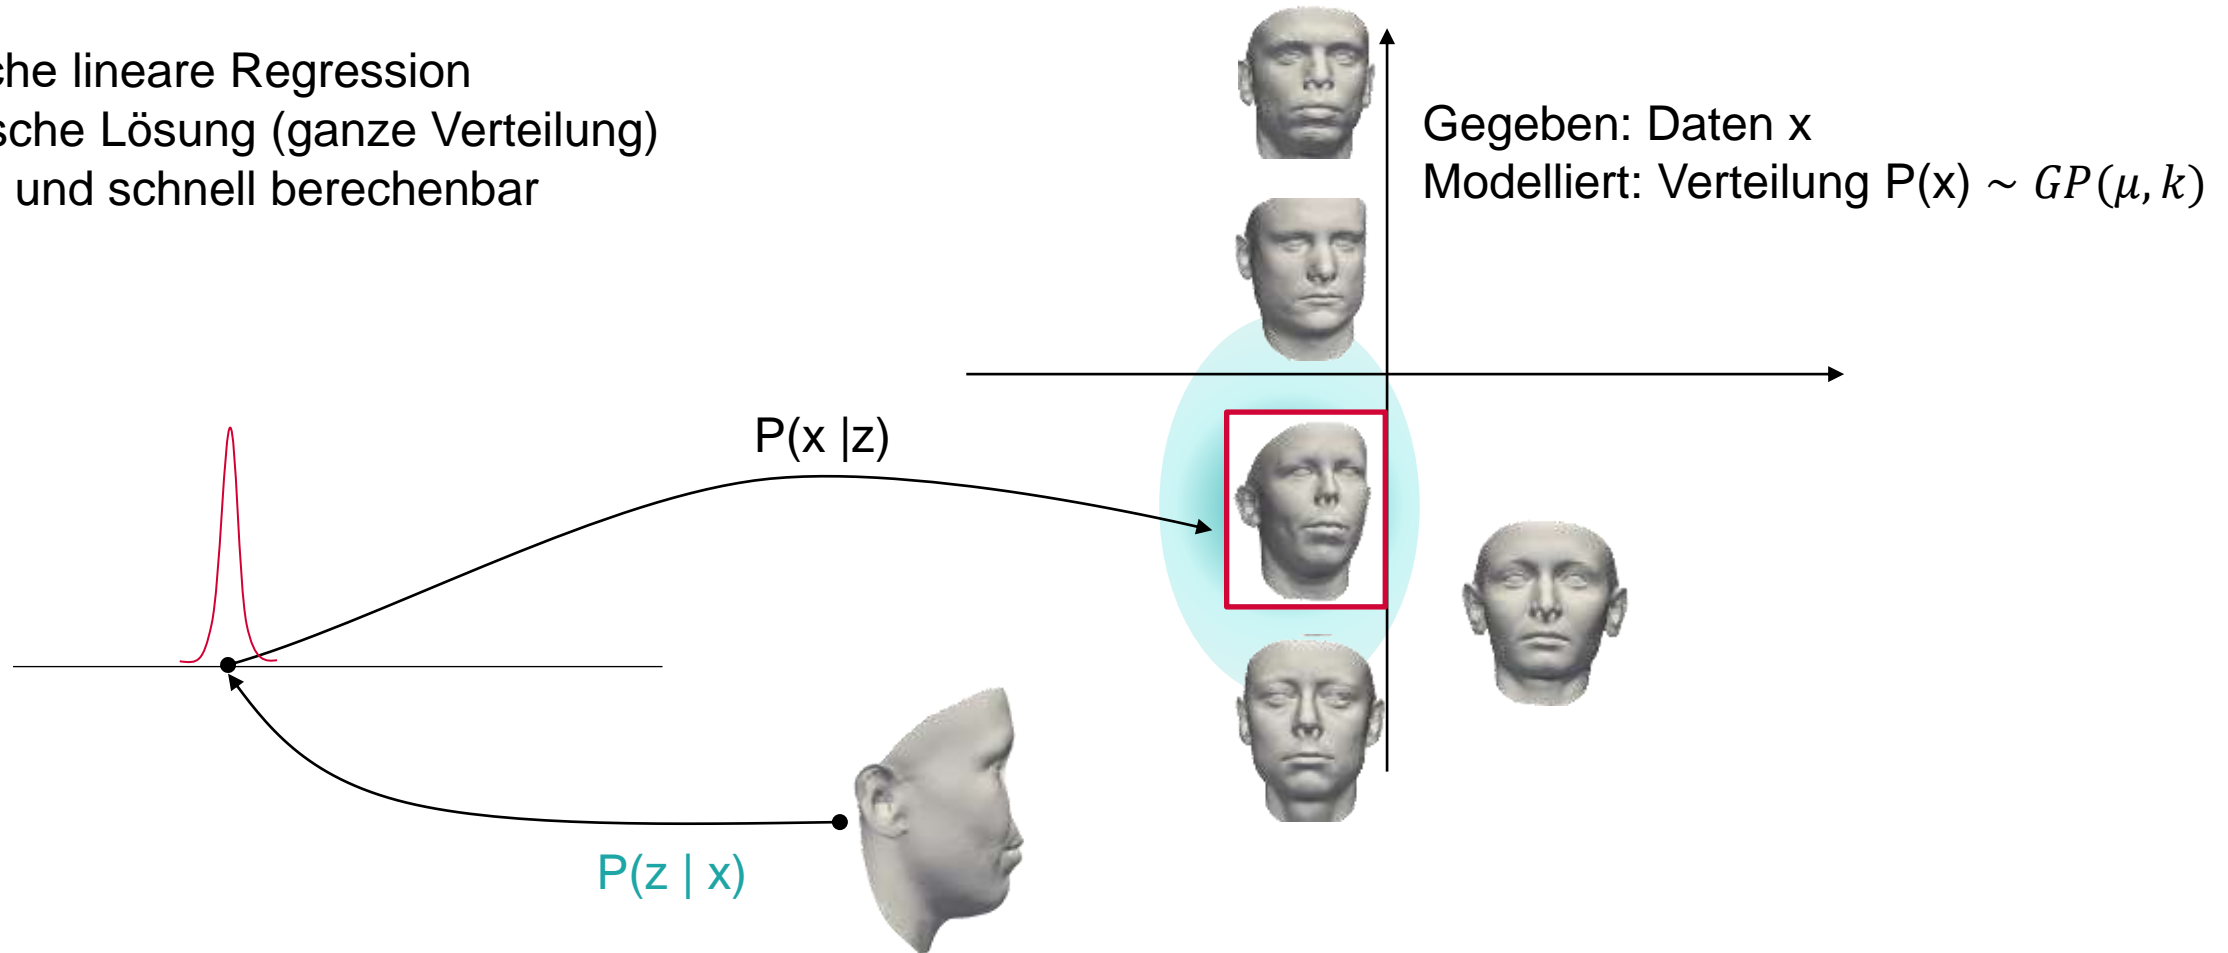
Bays'sche lineare Regression




Vorhersagen der Nase

Mathematisches Problem

Bays'sche lineare Regression
Analytische Lösung (ganze Verteilung)
Einfach und schnell berechenbar



Verteilung möglicher Nasen



Unsicherheit in der Vorhersage kann abgeschätzt und visualisiert werden.

GPMMs – KI der wir vertrauen können

Ziel des maschinellen Lernens




- Latenten Raum finden in der wir Daten einfach interpolieren können

Allgemeine KI-Ansätze

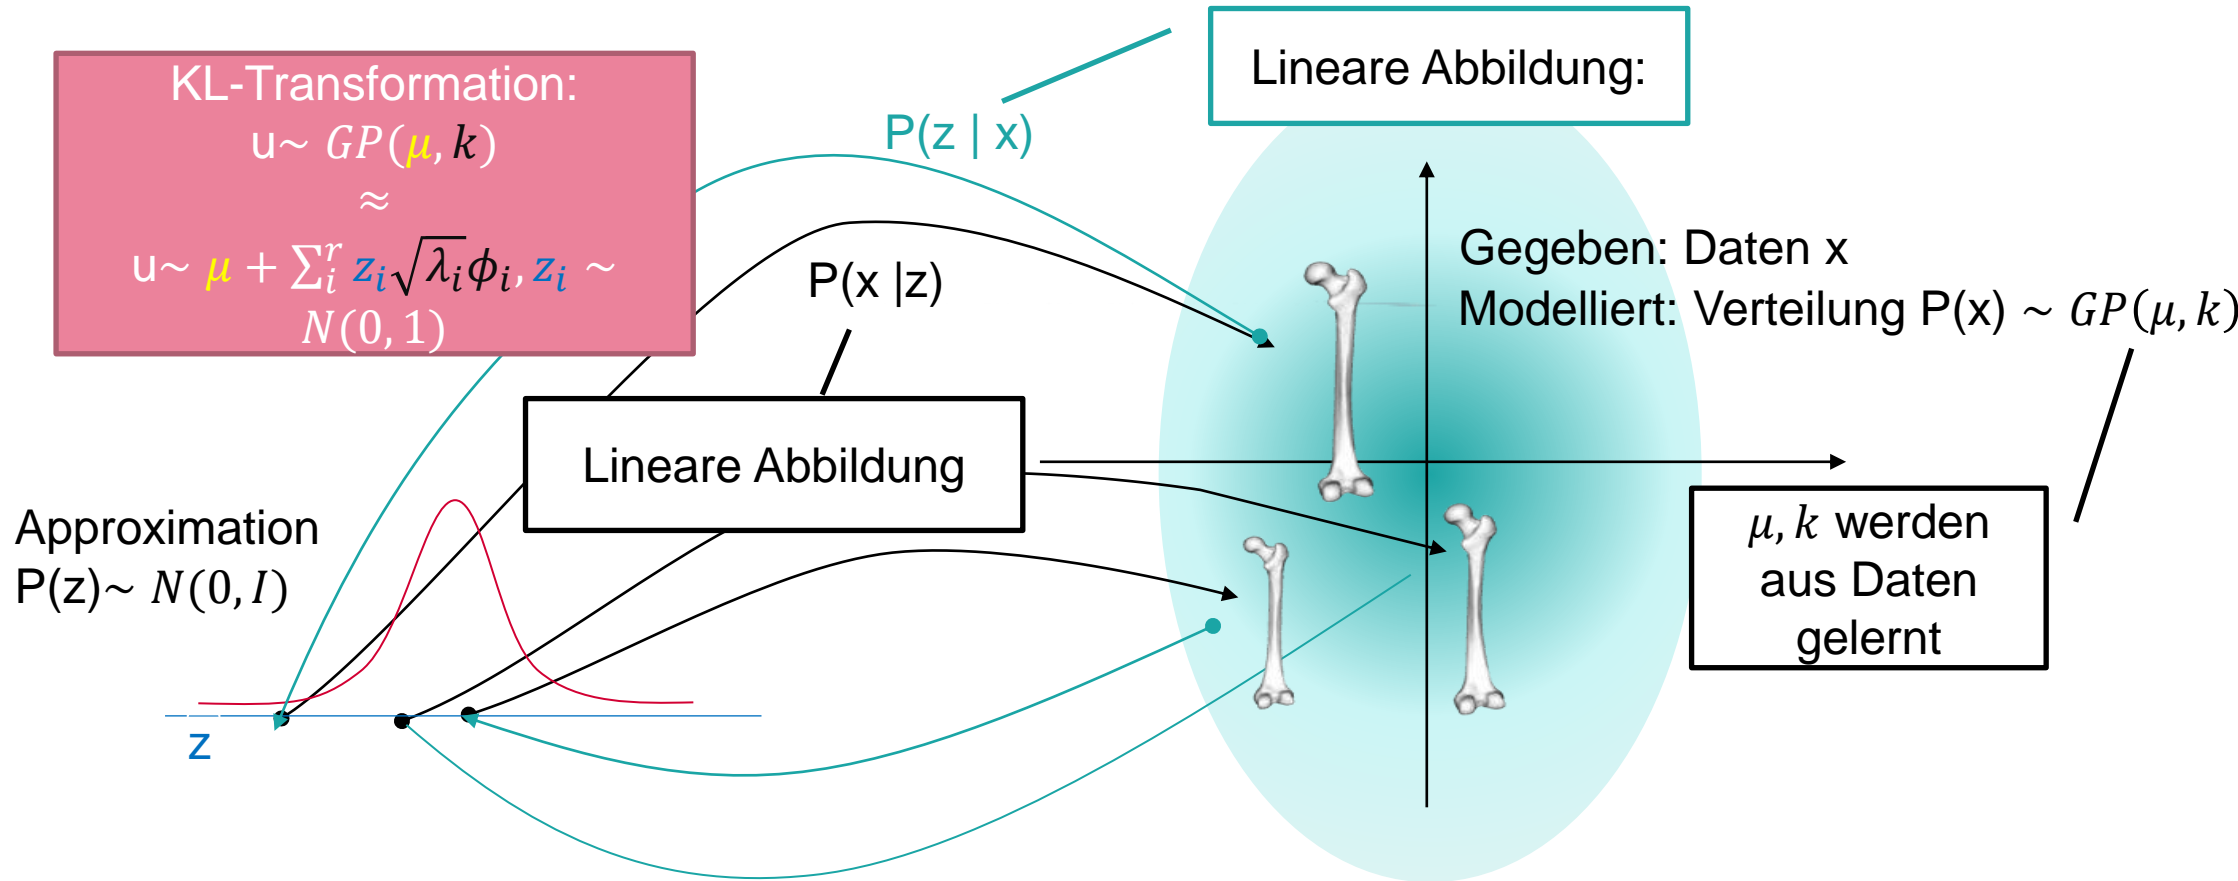
- + Enorme Flexibilität Neuronaler dank neuronaler Netze
- + Können beliebige Datenverteilungen repräsentieren
- Schwierig zu verstehen, wenig explizite Annahmen
- Oft sehr datenhungrig

Gaussian Process Morphable Models

- Eingeschränkt auf Normalverteilungen
- Explizite Modellierung benötigt
- + Modellierung passiert im Datenraum
- + Eigenschaften / Limitierungen können vollständig verstanden werden
- + Kann auf kleinen Datensätzen gelernt werden
- + Unsicherheit/Varianz aller Vorhersagen verfügbar



Danke für Ihre Aufmerksamkeit!



Implementation und Daten: <https://github.com/shape-the-world/nose-implant-case-study>
Kontakt: marcel.luethi@unibas.ch